

扫描件测试文档 第 1 页

本页面是纯光栅化图像，文字以像素形式绘制，
不包含任何可复制的文本层。

This page is a rasterized image with no extractable text layer.
Real scanned PDFs behave identically — MarkItDown and pypdf
return an empty string for pages like this.

当你用 OCR 工具（如 Tesseract、Azure Document Intelligence）
处理这类 PDF 时，才能拿到真实的文字内容。

Page body paragraph 2: lorem ipsum dolor sit amet, consectetur
adipiscing elit, sed do eiusmod tempor incididunt ut labore et
dolore magna aliqua. Ut enim ad minim veniam, quis nostrud
exercitation ullamco laboris nisi ut aliquip ex ea commodo.

扫描件测试文档 第 2 页

本页面是纯光栅化图像，文字以像素形式绘制，
不包含任何可复制的文本层。

This page is a rasterized image with no extractable text layer.
Real scanned PDFs behave identically — Markdown and pypdf
return an empty string for pages like this.

当你用 OCR 工具（如 Tesseract、Azure Document Intelligence）
处理这类 PDF 时，才能拿到真实的文字内容。

Page body paragraph 2: lorem ipsum dolor sit amet, consectetur
adipiscing elit, sed do eiusmod tempor incididunt ut labore et
dolore magna aliqua. Ut enim ad minim veniam, quis nostrud
exercitation ullamco laboris nisi ut aliquip ex ea commodo.

扫描件测试文档 第 3 页

本页面是纯光栅化图像，文字以像素形式绘制，
不包含任何可复制的文本层。

This page is a rasterized image with no extractable text layer.
Real scanned PDFs behave identically — Markdown and pypdf
return an empty string for pages like this.

当你用 OCR 工具（如 Tesseract、Azure Document Intelligence）
处理这类 PDF 时，才能拿到真实的文字内容。

Page body paragraph 2: lorem ipsum dolor sit amet, consectetur
adipiscing elit, sed do eiusmod tempor incididunt ut labore et
dolore magna aliqua. Ut enim ad minim veniam, quis nostrud
exercitation ullamco laboris nisi ut aliquip ex ea commodo.